

高级计量经济学II-6.受限因变量、Tobit模型、Heckman两步法



粥庆盐

北京大学博士研究生

收录于 · 高级计量经济学 >

11 人赞同了该文章 >

一、受限因变量⁺

Tobit模型用于受限因变量的删失或截断回归，因变量取值范围以某种方式受到约束。

目录

最早由 Tobin (1958) 在分析家庭耐用品支出时提出。设定 y 为家庭耐用品支出， y_0 为最便宜耐用品价格， z 为其他支出， x 为家庭收入。家庭在预算约束 $y + z \leq x$ 且 $y \geq y_0$ 或 $y = 0$ 下，最大化效用函数 $U(y, z)$ ，设 y_i^* 为 $\max U(y_i, z_i)$ ，约束条件为 $y_i + z_i \leq x_i$ ，且 $y_i^* = x_i' \beta + u_i$ 。

1、删失 (censored)

- 在数据统计或模型里，当观测值达到某个界限时，不是记录真实值，而是记录成这个界限值。比如用尺子量东西，尺子最长 1 米，若物体实际长 1.2 米，记录的是 1 米（上限截断）。
- 例如研究家庭耐用品支出时，家庭支出可能为 0（未购买耐用品）或大于 0（购买了耐用品）。没有支出时，就统一记录为 0；实际有支出（支出大于 0）的家庭，就记录其真实支出数值。
- Tobin (1958) 例子中，若观测值记录规则为 $y_i = y_i^*$ （当 $y_i^* > (或 <) c$ ）， $y_i = c$ （其他情况）， c 为常数， y_i^* 服从特定分布，此为删失模型。Tobin (1958) 的标准 Tobit 模型⁺中 $c = 0$ 。

2、截断 (truncated) 情况

- 只保留符合一定条件的数据，不符合条件的数据直接不记录、不参与分析。
- 例如在关于工资的研究中（如受教育程度对工资的影响），只记录了有工资的受访者数据，而忽略不工作的人。
- Tobin (1958) 例子中，若观测值记录规则为 $y_i = y_i^*$ （当 $y_i^* > (或 <) c$ ），其他情况不可观测，且 $y_i^* = x_i' \beta + u_i$ ， $u_i \sim (0, \sigma^2)$ ，阈值 y_{i0} 假定为 0，此为截断模型。

在受限因变量情况下，能否直接用 OLS 估计呢？不行！

3、OLS 不一致 (受限因变量下)

将 y_i 直接对 x_i 进行回归，得到的 $\hat{\beta}_{OLS}$ 是 β 的有偏且不一致估计量。

(1) 计算 $E(y_i | x_i)$

- 根据公式 $E(y_i | x_i) = Pr(y_i^* > 0) E(y_i^* | y_i^* > 0) + Pr(y_i^* < 0) \cdot 0$ ，将 $E(y_i^* | y_i^* > 0)$ 进一步展开为 $E(y_i^* | y_i^* > 0) = x_i' \beta + E(u_i | u_i > -x_i' \beta)$ ，此时重点关注 $E(y_i^* | y_i^* > 0) = x_i' \beta + E(u_i | u_i > -x_i' \beta)$ 的性质。

(2) 在 $u_i \sim i.i.d. N(0, \sigma^2)$ 条件下计算 $E(u_i | u_i > -x_i' \beta)$

$E(u_i | u_i > -x_i' \beta) = \sigma \frac{\phi(\frac{x_i' \beta}{\sigma})}{\Phi(\frac{x_i' \beta}{\sigma})} = \sigma \lambda(\frac{x_i' \beta}{\sigma})$, 其中 $\lambda(z) = \phi(z)/\Phi(z)$, $\lambda(\cdot)$ 被称为风险率 (hazard rate), 其倒数是 Mill's ratio。

$$E(u_i | u_i > -x_i' \beta) = \int_{-x_i' \beta}^{\infty} u_i f(u_i | u_i > -x_i' \beta) du \quad (3)$$

$$= \int_{-x_i' \beta}^{\infty} u_i f\left(\frac{u_i}{\sigma} \middle| \frac{u_i}{\sigma} > -\frac{x_i' \beta}{\sigma}\right) du \quad (4)$$

$$= \int_{-x_i' \beta}^{\infty} u_i \frac{\phi(\frac{u_i}{\sigma})}{1 - \Phi(-\frac{x_i' \beta}{\sigma})} du$$

$$= \frac{\sigma}{\Phi(\frac{x_i' \beta}{\sigma})} \int_{-\frac{x_i' \beta}{\sigma}}^{\infty} \frac{u_i}{\sigma} \phi(\frac{u_i}{\sigma}) d(\frac{u_i}{\sigma}),$$

where $\phi(\frac{u}{\sigma}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{u^2}{2\sigma^2}\right)$.

Since the standard normal density function of $u^* = u/\sigma$ is

$$\phi(u^*) = \frac{1}{\sqrt{2\pi}} e^{-u^{*2}/2},$$

we have

$$\phi'(u^*) = -u^* \frac{1}{\sqrt{2\pi}} e^{-u^{*2}/2} = -u^* \phi(u^*).$$

(3) becomes

$$E(u_i | u_i > -x_i' \beta) = -\frac{\sigma}{\Phi(\frac{x_i' \beta}{\sigma})} \int_{-\frac{x_i' \beta}{\sigma}}^{\infty} u^* \phi(u^*) du^* \quad (5)$$

$$= -\frac{\sigma}{\Phi(\frac{x_i' \beta}{\sigma})} \phi(u^*) \Big|_{-\frac{x_i' \beta}{\sigma}}^{\infty}$$

$$= \sigma \frac{\phi(\frac{x_i' \beta}{\sigma})}{\Phi(\frac{x_i' \beta}{\sigma})} = \sigma \lambda\left(\frac{x_i' \beta}{\sigma}\right).$$

(3) 得出 $E(y_i^* | y_i^* > 0)$ 表达式并分析子样本情况

- 将 $E(u_i | u_i > -x_i' \beta)$ 的结果代入 $E(y_i^* | y_i^* > 0) = x_i' \beta + E(u_i | u_i > -x_i' \beta)$, 得到 $E(y_i^* | y_i^* > 0) = x_i' \beta + \sigma \lambda(\frac{x_i' \beta}{\sigma})$ 。
- 对于 $y_i^* > 0$ (即 $y_i = y_i^* > 0$) 的子样本, $y_i = E(y_i | x_i) + \varepsilon_i$
 $= E(y_i^* | y_i^* > 0, x_i) + \varepsilon_i = x_i' \beta + \sigma \lambda(\frac{x_i' \beta}{\sigma}) + \varepsilon_i$, 且 $E(\varepsilon_i | x_i) = 0$ 。

(4) 分析 $\hat{\beta}_{OLS}$ 的性质:

- 根据普通最小二乘法 (OLS) 公式 $\hat{\beta}_{OLS} = (X'X)^{-1}X'Y$, 将 $Y = X\beta + \sigma\lambda + \varepsilon$ 代入, 得到 $\hat{\beta}_{OLS,1} = \beta + \sigma(X'X)^{-1}X'\lambda + (X'X)^{-1}X'\varepsilon$ 。
- 由于 $\frac{1}{N}(X'X)^{-1}$ 趋于一个非奇异矩阵 A , $\frac{1}{N}(X'X)^{-1}X'\varepsilon$ 趋于 0, 而 λ 是 $X\beta$ 和 σ 的函数, 所以 $\hat{\beta}_{OLS}$ 是 β 的有偏且不一致估计量。

二、Tobit Model: MLE方法

关于作者



粥厌盐

北京大学博士研究生

回答

87

文章

131

关注者

558

关注她

发私信

大家都在搜

换一换

美国白宫记者晚宴发生枪... 454 万 热

国安部披露境外组织资助... 358 万 热

25 岁女孩确诊黑色素瘤 5... 336 万 热

迪士尼游客劝烟被连扇 5 耳光 323 万

黄杨钿甜首次回应耳环风波 323 万 热

网红白冰偷税被查 292 万 热

东方甄选 4 名主播集体离职 283 万

中山大学作息新方案引发... 282 万 热

DeepSeek V4 预览版上线... 278 万

1、定义指示变量并构建似然函数

定义 $d_i = 1(y_i > 0)$ ，在此基础上构建删失样本的似然函数 L_c 。

$L_c = \Pr(y_1, \dots, y_N)$ ，它被表示为两部分连乘的形式。

$$L_c = \prod_0 (1 - \Phi(\frac{x'_i \beta}{\sigma})) \prod_1 \Phi(\frac{x'_i \beta}{\sigma}) f(u_i | d_i = 1)$$

其中 $\prod_0 \Pr(d_i = 0)$ 是针对 $y_i = 0$ 的 N_0 个观测值，

$\prod_1 (\Pr(d_i = 1) \cdot f(u_i | d_i = 1))$ 是针对 $y_i > 0$ 的 N_1 个观测值。

2、计算 $f(u_i | d_i = 1)$ 并化简似然函数

根据已知条件计算 $f(u_i | d_i = 1)$ ，将其表达式 $f(u_i | d_i = 1) = \frac{1}{\Phi(\frac{x'_i \beta}{\sigma})} \cdot \frac{1}{\sigma} \phi(\frac{y_i - x'_i \beta}{\sigma})$

代入似然函数 L_c ，得到 $L_c = \prod_0 (1 - \Phi(\frac{x'_i \beta}{\sigma})) \prod_1 \frac{1}{\sigma} \phi(\frac{y_i - x'_i \beta}{\sigma})$ 。

3、分解似然函数 L_c

将 L_c 重新表示为两部分的乘积，即 $L_c = \prod_0 (1 - \Phi(\frac{x'_i \beta}{\sigma})) \prod_1 \Phi(\frac{x'_i \beta}{\sigma}) \times L_t$ 。

- 其中第一部分 $\prod_0 (1 - \Phi(\frac{x'_i \beta}{\sigma})) \prod_1 \Phi(\frac{x'_i \beta}{\sigma})$ 是 probit 模型的似然函数，
- 第二部分 $L_t = \prod_1 \frac{1}{\sigma} \phi(\frac{y_i - x'_i \beta}{\sigma})$ 是截断样本的似然函数。

4、对比截断前后概率

$$\begin{aligned} f(y) &= \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left\{-\frac{1}{2}\left(\frac{y_i - \mathbf{x}'_i \beta}{\sigma}\right)^2\right\} \\ \text{截断前的概率密度} &= \frac{1}{\sigma} \phi\left(\frac{y_i - \mathbf{x}'_i \beta}{\sigma}\right) \end{aligned}$$

- 截断后样本被观测到的概率 $\Pr(y_i > c | \mathbf{x}_i) = 1 - \Pr(y_i \leq c | \mathbf{x}_i)$

$$\begin{aligned} \Pr(y_i > c | \mathbf{x}_i) &= 1 - \Pr(y_i \leq c | \mathbf{x}_i) \\ &= 1 - \Pr\left(\frac{y_i - \mathbf{x}'_i \beta}{\sigma} \leq \frac{c - \mathbf{x}'_i \beta}{\sigma} | \mathbf{x}_i\right) \\ &= 1 - \Pr\left(\frac{u_i}{\sigma} \leq \frac{c - \mathbf{x}'_i \beta}{\sigma} | \mathbf{x}_i\right) \\ &= 1 - \Phi\left(\frac{c - \mathbf{x}'_i \beta}{\sigma}\right) \end{aligned}$$

三、Heckman's Sample Selection Model

1、样本选择问题定义

主要用于解决样本选择偏差问题，这种偏差通常是由于样本不是随机选取的，可能存在非随机性抽样或样本自选择情况。例如在研究劳动力市场中女性工资时，可能存在选择偏差，因为不是所有女性都参与劳动力市场，参与工作的女性可能与不参与工作的女性存在系统性差异。

- 当因变量 y 的断尾与另一个变量 z_i 相关时，存在样本选择问题， z_i 为选择变量。
- 通过 $y_i = X'_{1i} \beta + u_i$ 和 $D_i = 1(X'_{2i} \gamma + v_i > 0)$ ， y_i 为结果变量。

以女性为研究对象时， y_i 是女性工资的自然对数。不过当 $y_i = 1$ （即女性没有工作）

）时，工资数据才能被观测到，未参加工作女性工资数据缺失。如 $\ln(\text{hours}) = \beta_0 + \beta_1 \text{wage} + \beta_2 \text{children} + \dots + u$ ，当工作获得工资低于保底工资时，女性不工作，观测不到劳动时间，产生样本选择问题。

3、OLS 估计的局限性

在 $y = x'\beta + u$ ， $u|x \sim N(0, \sigma^2)$ ， $y|x \sim N(x'\beta, \sigma^2)$ 条件下， $E(y_i | y_i > c) = x'_i \beta + \sigma \lambda(\frac{c - x'_i \beta}{\sigma})$ ，遗漏项与 x_i 相关，直接用 OLS 估计会得到不一致结果。

4、Heckman 两步法⁺

(1) 方法

- **第一步**：对选择方程进行估计，利用得到的参数计算 Inverse Mill' s Ratio。
- **第二步**：将 Inverse Mill' s Ratio 作为额外解释变量加入主回归模型。

(2) remark

- 识别时需要有排他性约束，即至少有一个工具变量。
- **示例说明**：主回归方程涉及女性工资、工作经历、教育程度变量；决策方程考虑女性是否工作，涉及婚姻状况、孩子数量、教育程度；排他性约束变量为女性是否结婚和孩子数量，假设它们仅通过影响女性是否工作来间接影响工资金额，而非直接影响。

编辑于 2025-04-12 17:43 · 北京

Tobit

经济学

计量经济学



未登录用户



还没有评论，发表第一个评论吧



计量经济学：模型的转化与引入虚拟变量的回归

菱小攀

阵X列满秩判断估计量优劣的标准是什么？估计量的均值是否等于真实值：无偏性（即OLS假定2:随机误差项（就是随即干扰项）的总体均值为0）+（OLS假定3:随机误...

嗨喽



应用计量经济学·第十二章：进阶面板数据·第一节：固定效...

北美老虎哥... 发表于跨界自学 ...



计量经济学：简单线性回归模型及预测

Vincy